Klasterisasi Time Series Multivariat 29 Sensor Boiler Batu Bara Menggunakan K-Means Berbasis Non-overlapping Windows

Hamzah Abdillah Gabriela
Teknik Informatika
Universitas Padjadjaran
Sumedang, Indonesia
hamzah24001@mail.unpad.ac.id

Renadi Wilantara
Teknik Informatika
Universitas Padjadjaran
Sumedang, Indonesia
renadi24001@mail.unpad.ac.id

Muhammad Rizky Khitami
Teknik Informatika
Universitas Padjadjaran
Sumedang, Indonesia
muhammad24207@mail.unpad.ac.id

Khalit Putra Afana
Teknik Informatika
Universitas Padjadjaran
Sumedang, Indonesia
khalit24001@mail.unpad.ac.id

Muhammad Fathin Raihan
Teknik Informatika
Universitas Padjadjaran
Sumedang, Indonesia
muhammad24028@mail.unpad.ac.id

Abstrak*—Data sensor boiler industri berbentuk deret waktu multivariat tanpa label dengan ketimpangan skala yang besar, ketergantungan waktu yang kuat, serta nilai hilang dan outlier. Penelitian ini mengklaster kondisi operasi boiler batu bara dari dataset publik berisi 86.400 sampel berinterval 5 detik, dengan 29 sensor proses sebagai fitur dan suhu uap keluaran boiler sebagai acuan eksternal. Delapan studi rujukan dipilih melalui PRISMA 2020 dan dianalisis celah penelitiannya. Praproses meliputi time-based linear interpolation, winsorizing menggunakan Tukey fence 3×IQR, dan RobustScaler. Temporal dependency dipertahankan menggunakan non-overlapping window 5 menit dengan fitur mean, standard deviation (std), dan slope untuk setiap sensor. Representasi tersebut kemudian direduksi menggunakan Principal Component Analysis (PCA) dengan Kaiser criterion sebelum diklaster menggunakan K-Means. Kandidat jumlah klaster dievaluasi menggunakan Elbow Method, Silhouette Coefficient, dan Davies–Bouldin Index (DBI), dengan nilai k final ditentukan berdasarkan Silhouette tertinggi. Representasi jendela menghasilkan Silhouette 0,260 pada dua klaster, lebih tinggi daripada K-Means titik per titik (0,166) dan rata-rata jendela (0,174), tetapi Davies–Bouldin Index-nya lebih buruk (2,408 berbanding 2,019 dan 1,955). Klaster kecil yang mencakup 12,6 persen waktu mencerminkan episode singkat fluktuasi tekanan tungku, dan porsi suhu uap di luar rentang normal pada klaster ini 1,6 kali lebih besar daripada pada klaster stabil. Struktur klaster secara umum lemah karena boiler beroperasi dalam satu rezim kontinu, tetapi representasi temporal mampu mengungkap kondisi stabilitas dinamis yang tidak terlihat oleh pendekatan titik per titik.

Kata kunci—boiler industri, deret waktu multivariat, klasterisasi deret waktu, K-Means, jendela geser, PRISMA

I. PENDAHULUAN

A. Latar Belakang dan Permasalahan Data Sensor Multivariat

Boiler industri merupakan peralatan penting pada pembangkitan listrik dan proses industri [1]. Pemantauannya melalui Distributed Control System (DCS) menghasilkan multivariate time series dari sensor tekanan, suhu, aliran, oksigen, getaran, dan arus motor yang merekam dinamika operasi.

Penelitian ini menggunakan dataset publik boiler batu bara dari pabrik kimia di Zhejiang, Tiongkok [1], [2]: 86.400 sampel berinterval 5 detik pada 27 Maret–1 April 2022, dengan 30 atribut numerik kontinu tanpa label klaster. Sebanyak 29 sensor menjadi fitur klasterisasi, sedangkan suhu uap keluaran TE_8332A menjadi acuan eksternal. Kondisi operasi ditemukan melalui unsupervised learning dan dievaluasi dengan metrik internal.

Data menghadirkan tiga tantangan. Pertama, scale disparity: FT_8301 bernilai 40.773–53.047, sedangkan AIR_8301A hanya 0,78–4,56. Tanpa scaling, sensor berskala besar mendominasi jarak Euclidean pada K-Means; scaling belum eksplisit pada sebagian studi industri [3]. Kedua, temporal dependency: observasi berinterval 5 detik saling berkorelasi, sehingga pemodelan titik per titik mengabaikan dinamika [4]. Ketiga, nilai hilang dan outlier akibat gangguan pengukuran [1]. Data mentah memuat 30 nilai hilang pada YJJWSLL; penyusun dataset melaporkan sekitar 8,6% suhu uap di luar 530–545 °C [1].

Penelitian bertujuan mengelompokkan kondisi operasi dari 29 sensor dengan praproses dan representasi dinamika temporal, lalu menafsirkan klaster terhadap suhu uap keluaran. Jumlah dan kualitas klaster dinilai menggunakan Silhouette Coefficient [5] dan Davies–Bouldin Index (DBI) [6].

B. Seleksi Literatur dengan Metode PRISMA

Literatur acuan diseleksi mengikuti pedoman *Preferred Reporting Items for Systematic Reviews and Meta-Analyses* (PRISMA) 2020 [7]. Alur seleksi ditunjukkan pada Fig. 1. Tahap identifikasi menggunakan basis data Scopus dengan kueri *Boolean* (“industrial” OR “coal-fired boiler”) AND (“multivariate time series” OR “time series” OR “time-series”) AND (cluster*), yang menghasilkan 937 rekaman. Tidak ada rekaman duplikat ataupun rekaman yang dikeluarkan oleh alat otomatis.

Pada tahap penyaringan, 420 rekaman yang terbit sebelum 2022 dikeluarkan sehingga 517 laporan dicari teks lengkapnya. Sebanyak 309 laporan tidak dapat diakses, sehingga 208 laporan dinilai kelayakannya melalui pembacaan teks lengkap. Pada tahap kelayakan, 38 laporan dikeluarkan karena bukan artikel, 5 laporan karena tidak berbahasa Inggris, dan 103 laporan karena di luar cakupan. Hasilnya, 62 studi memenuhi kriteria inklusi. Dari 62 studi tersebut, delapan artikel dengan kedekatan tertinggi terhadap topik klasterisasi data sensor industri multivariat ditetapkan sebagai rujukan utama [3], [4], [8]–[13].

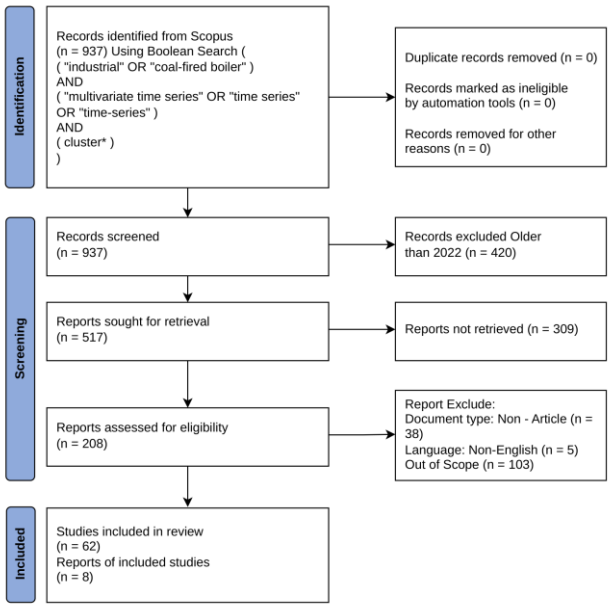


Fig. 1. Diagram alir PRISMA 2020 untuk seleksi literatur: 937 rekaman teridentifikasi dari Scopus hingga 8 artikel rujukan utama.

C. *Tinjauan Studi Terkait dan Analisis Gap*

Tabel I membandingkan delapan studi berdasarkan domain, praproses, representasi temporal, algoritma, penentuan parameter, evaluasi, dan gap penelitian.

Studi penemuan kondisi operasi mencakup K-Means titik per titik pada distilasi [3], segmentasi manual gangguan gardu pemanas dengan SOM dan K-Means [10], serta fitur aktivasi peralatan dapur dengan PCA dan K-Means [11]. Enes et al. [8] menyusun pipeline berbasis fitur per HPC job. Keterbatasannya meliputi scaling yang belum eksplisit, segmentasi manual, dan representasi per entitas yang belum menangkap dinamika multivariat dalam aliran kontinu.

Köhne et al. [4] memodelkan subsekuens multivariat secara online dengan RNN autoencoder, tetapi memerlukan banyak hiperparameter dan input yang telah dibersihkan. Studi deteksi anomali menggunakan multi-view clustering pada transformator [9], UMAP–DBSCAN untuk pengelompokan sensor [12], serta MTGNN dengan DBSCAN dan Isolation Forest [13]. Pendekatan tersebut tidak berfokus pada interpretasi mode operasi dan tidak selalu mengevaluasi kualitas klaster secara internal.

TABLE I. RINGKASAN ANALISIS GAP DELAPAN STUDI RUJUKAN UTAMA

Ref.	Domain dan data	Nilai hilang	Outlier / noise	Scaling	Penanganan temporal	Algoritma klaster	Penentuan k / parameter	Evaluasi klaster	Gap utama
[3]	Distilasi bio 2,3-BDO; 7 variabel; 5.760 titik, interval 1 menit	LPF disebut, tetapi tidak ada data hilang	LPF; deteksi outlier tidak dilakukan	Tidak eksplisit	Tidak ada; tiap titik independen	K-Means (Euclidean)	WCSS + Elbow (perubahan < 2%), k = 7	WCSS saja	Tanpa scaling dan temporal; tanpa Silhouette/DBI
[8]	Job HPC (CPU, memori) superkomputer	Fitur bernilai NaN/Inf dihapus	LOF + Isolation Forest (opsional)	StandardScaler	Fitur statistik dan tsfresh per job; downsampling	K-Means, Agglomerative (+PCA, Kernel PCA)	Banyak kombinasi; peringkat heuristik	Silhouette, DBI, CH	Satu vektor per entitas; dinamika dalam aliran tidak dimodelkan
[9]	Transformator konverter 800 kV; 8.760 titik per jam	Interpolasi bertingkat	Outlier menjadi target deteksi	Robust (median, IQR)	Fitur multi-skala, differencing	K-Means, HDBSCAN, OPTICS, IF pada 4 view	Silhouette untuk k; elbow k-distance	SC, DBI, CHI, OSS	Untuk deteksi outlier, bukan mode operasi; kompleks
[4]	Sistem mekatronik; 8 dataset (mis. hidraulik, 17 sensor)	Harus bebas sebelumnya	Harus dihapus sebelumnya	Standardisasi	Sliding window, subsekuens	ABIMCA (RNN autoencoder)	Random grid search; banyak ambang	SC, CH, DBI, MT3SCM	Kompleks; banyak hiperparameter
[10]	Gardu pemanas distrik; meter panas per jam	Data terpotong; tanpa imputasi	BEAST (usulan, proof of concept)	Tidak eksplisit	Segmentasi manual periode gangguan	SOM + K-Means	Grid SOM 4×4; k = 5 dari Silhouette	Silhouette; laporan gangguan	Segmentasi manual; tanpa scaling eksplisit
[11]	9 peralatan dapur industri; 5 dtk ke 30 dtk	Interpolasi linear berbasis waktu	Aturan 3σ	Standardisasi (z-score)	Segmentasi aktivasi ON/OFF	K-Means (+catch24, PCA)	k = 2–8 dengan Silhouette tertinggi	Silhouette saja	Per peralatan (univariat); 17 hari
[12]	SWaT, WaDi, SMD (38 variabel)	Tidak dibahas	Normalisasi error median/IQR	Hanya pada error prediksi	Sliding window; konvolusi 1D	UMAP + DBSCAN (klaster sensor)	eps = 2, min_samples = 10 tetap	AUC (berlabel); tanpa metrik klaster	Kualitas klaster tidak diukur
[13]	Sensor metana tambang batu bara; 4 node, 30 dtk	Tidak dijelaskan	Anomali menjadi target (IF + DBSCAN)	z-score	Sliding window 100; MTGNN	DBSCAN + IF berbobot Bayesian	eps dari k-distance; optimasi Bayesian	F1 terhadap pseudo-label	Bukan klasterisasi mode operasi; data tertutup
Studi ini	**Boiler batu bara; 29 sensor + 1 acuan; 86.400 sampel, 5 dtk**	**Interpolasi linear berbasis waktu**	**Winsorizing pagar 3×IQR**	**RobustScaler (median, IQR)**	**Jendela 5 menit: mean, std, slope**	**K-Means + PCA (Kaiser)**	**Elbow, Silhouette, DBI**	**Silhouette, DBI; acuan TE_8332A**	**Menutup celah scaling, temporal, dan evaluasi**

[a] LPF: low-pass filter; LOF: Local Outlier Factor; IF: Isolation Forest; CH/CHI: Calinski–Harabasz; SC: Silhouette Coefficient; DBI: Davies–Bouldin Index; OSS: Outlier Separation Score.

Tabel I mengidentifikasi empat gap: scaling belum konsisten [3], [10]; dinamika temporal diabaikan atau ditangani dengan model kompleks [3], [4], [12], [13]; penanganan nilai hilang dan outlier belum selalu diuji [3], [4], [12], [13]; serta evaluasi klaster terbatas pada WCSS, satu metrik, atau label semu [3], [11]–[13]. Delapan studi tersebut belum mencakup klasterisasi kondisi boiler batu bara dengan 29 sensor dan scale disparity ekstrem.

D. Kontribusi Penelitian

Berdasarkan celah tersebut, kontribusi kelompok dalam penelitian ini adalah sebagai berikut.

- Menyusun alur praproses yang terdokumentasi untuk 29 sensor boiler, meliputi interpolasi nilai hilang, *winsorizing* outlier ekstrem, dan *robust scaling* untuk mengatasi ketimpangan skala sebelum perhitungan jarak *Euclidean*.
- Merepresentasikan dinamika temporal melalui non-overlapping windows berisi mean, simpangan baku, dan slope per sensor, sebagai pendekatan ringan dibandingkan model berbasis deep learning [4].
- Merancang klasterisasi K-Means dengan penentuan jumlah klaster melalui *Elbow Method*, *Silhouette Coefficient*, dan *Davies–Bouldin Index*, lalu membandingkannya dengan dua *baseline*: K-Means titik per titik dan K-Means pada rata-rata jendela.
- Menginterpretasikan klaster sebagai kondisi operasi boiler dengan suhu uap keluaran (TE_8332A, rentang normal 530–545 °C [1]) sebagai acuan eksternal yang tidak dipakai dalam proses klasterisasi.

II. Metodologi Preprocessing dan Pemodelan

A. Dataset dan Pemilihan Variabel

Data berasal dari xinan_uncompleted_data.csv [1], [2], berisi 86.400 baris berinterval 5 detik tanpa timestamp duplikat. Fitur mencakup 29 sensor: tekanan (PT_8313A–F, pot pressure PTCA_8322A, outlet vapour pressure PTCA_8324, SXLTCYZ, SXLTCYY, ZCLCCY, YCLCCY), suhu (TE_8319A/B, TE_8313B, TE_8303/4), aliran (FT_8301/2, FT_8306A/B, YJJWSLL, ZZQBCHLL), oksigen (AIR_8301A/B), arus dan getaran ID fan (YFJ3_AI, YFJ3_ZD1/2), serta katup TV_8329ZC. Atribut ke-30, TE_8332A, hanya menjadi acuan eksternal agar interpretasi tidak sirkuler. Alur penelitian ditunjukkan pada Fig. 2.

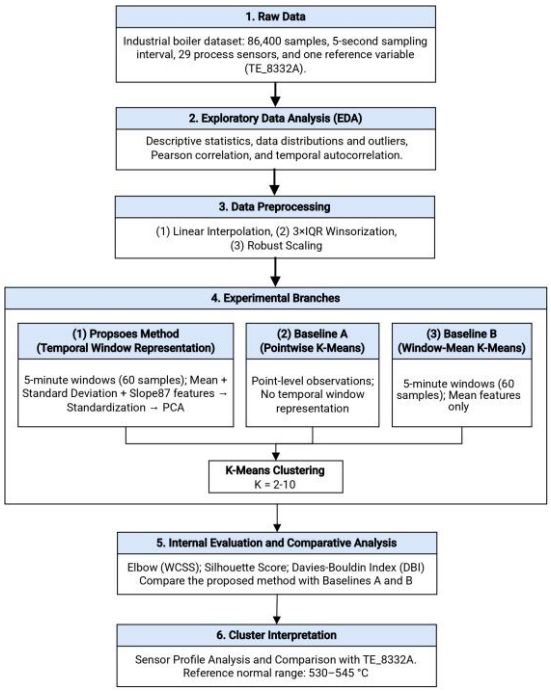


Fig. 2. Alur penelitian: pemahaman data dan EDA, praproses, representasi jendela temporal, reduksi dimensi, klasterisasi K-Means, evaluasi internal, dan interpretasi terhadap acuan eksternal.

B. Analisis Data Eksploratif

EDA data mentah mencakup statistik deskriptif (mean, simpangan baku, minimum, maksimum, rentang, skewness, kurtosis), boxplot pada skala (x − median)/IQR, dan penghitungan outlier dengan Tukey fence 1,5×IQR serta 3×IQR [14]. Korelasi Pearson mengukur redundansi sensor; autokorelasi pada lag 5 detik, 1, 5, 30 menit, dan 1 jam mengukur temporal dependency.

C. Teknik Penanganan Data

Praproses terdiri atas tiga langkah. Pertama, nilai hilang diisi dengan interpolasi linear berbasis waktu. Untuk nilai hilang pada waktu t yang diapit observasi valid pada waktu t_a dan t_b, nilai pengganti dihitung dengan

$$x_t = x_a + (x_b - x_a)\frac{t - t_a}{t_b - t_a}. \quad (1)$$

Interpolasi dipilih karena celah terpanjang hanya 28 sampel (140 detik), sehingga menggunakan pola lokal di sekitar celah. Penyusun dataset memakai AutoReg [1].

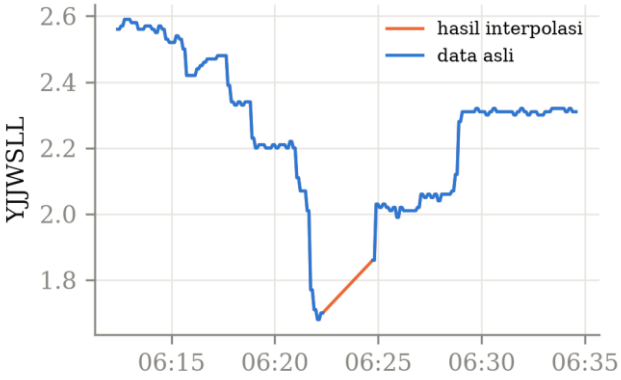


Fig. 3. Interpolasi linear berbasis waktu untuk mengisi missing value pada sensor YJJWSLL

Kedua, outlier ekstrem ditangani dengan *winsorizing* pada Tukey fence 3×IQR [14]. Nilai di luar pagar dipotong ke batas pagar, tidak dibuang, sehingga urutan waktu tetap utuh:

$$x'_t = \min\{\max\{x_t, Q_1 - 3 \cdot \mathrm{IQR}\}, Q_3 + 3 \cdot \mathrm{IQR}\}, \quad (2)$$

dengan Q_1 dan Q_3 sebagai kuartil pertama dan ketiga tiap sensor. Pagar 1,5×IQR tidak dipakai karena akan memotong variasi operasi yang sah. Ketiga, ketimpangan skala diatasi dengan *robust scaling* berbasis median dan IQR, sebagaimana dipakai pada data transformator yang berekor panjang [9]:

$$z_t = \frac{x'_t - \mathrm{med}(x')}{\mathrm{IQR}(x')}. \quad (3)$$

D. Representasi Temporal Jendela Geser

Dinamika temporal dirangkum melalui non-overlapping windows sepanjang W = 60 sampel (5 menit). Tanpa overlap, observasi tidak berulang pada jendela berbeda. Untuk setiap jendela w dan sensor j, dihitung mean (level), simpangan baku (variabilitas), dan slope regresi linear (tren lokal):

$$\mu_{w,j} = \frac{1}{W}\sum_{t=1}^{W} z_{w,t,j}, \quad (4)$$

$$\sigma_{w,j} = \sqrt{\frac{1}{W-1}\sum_{t=1}^{W}\left(z_{w,t,j} - \mu_{w,j}\right)^2}, \quad (5)$$

$$\beta_{w,j} = \frac{\sum_{t=1}^{W}(t-\bar{t})z_{w,t,j}}{\sum_{t=1}^{W}(t-\bar{t})^2}, \quad (6)$$

dengan $\bar{t} = (W+1)/2$. Setiap jendela direpresentasikan oleh $3 \times 29 = 87$ fitur. Fitur tersebut distandardisasi, lalu direduksi dengan *Principal Component Analysis* (PCA) menggunakan kriteria Kaiser, yaitu hanya komponen dengan *eigenvalue* lebih dari satu yang dipertahankan [15], [11]. Reduksi ini juga mengurangi bobot berlebih dari sensor yang saling redundan.

E. Formulasi Algoritma Klasterisasi

Klasterisasi menggunakan K-Means [16]. Diberikan n vektor komponen utama p_i, K-Means mencari k pusat klaster m_c yang meminimalkan jumlah kuadrat jarak *Euclidean* di dalam klaster (WCSS):

$$J = \sum_{c=1}^{k}\sum_{p_i \in C_c}\|p_i - m_c\|^2. \quad (7)$$

K-Means memperbarui keanggotaan dan pusat klaster hingga konvergen. Inisialisasi memakai k-means++, 10 inisialisasi ulang, dan random state 42.

F. Rancangan Evaluasi Klaster

Jumlah klaster diuji pada k = 2 hingga 10 dengan tiga kriteria. *Elbow Method* mencari titik siku pada kurva WCSS, yang ditentukan secara otomatis sebagai titik dengan jarak terjauh dari garis lurus yang menghubungkan ujung-ujung kurva ternormalisasi. *Silhouette Coefficient* [5] mengukur kohesi dan separasi tiap titik:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \quad (8)$$

dengan $a(i)$ sebagai rata-rata jarak titik i ke anggota klasternya sendiri dan $b(i)$ sebagai rata-rata jarak ke klaster terdekat lainnya. Nilai Silhouette keseluruhan adalah rata-rata $s(i)$, dengan rentang −1 hingga 1 (lebih tinggi lebih baik). *Davies–Bouldin Index* [6] membandingkan sebaran di dalam klaster dengan jarak antarpusat (lebih rendah lebih baik):

$$\text{DBI} = \frac{1}{k}\sum_{i=1}^{k}\max_{j \neq i}\frac{S_i + S_j}{d(m_i, m_j)}, \quad (9)$$

dengan S_i sebagai rata-rata jarak anggota klaster i ke pusatnya. Nilai k final ditetapkan dari Silhouette tertinggi, sedangkan Elbow dan DBI dipakai sebagai pembanding. Setelah klaster terbentuk, setiap klaster dibandingkan dengan acuan eksternal TE_8332A, yaitu rata-rata suhu uap dan persentase sampel di luar rentang normal 530–545 °C.

G. Rancangan Eksperimen

Ketiga representasi memakai praproses dan kriteria PCA yang sama. Baseline A mengklaster 86.400 observasi per 5 detik tanpa fitur temporal [3]; baseline B memakai mean jendela 5 menit tanpa simpangan baku dan slope. Silhouette baseline A dihitung pada 10.000 titik acak karena kompleksitasnya kuadratik. Sensitivitas diuji pada W = 12, 60, 120, dan 360 sampel (1, 5, 10, 30 menit), untuk k = 2–4.

III. HASIL

A. Hasil Analisis Data Eksploratif

Statistik deskriptif ringkas ditunjukkan pada Tabel II. Ketimpangan skala sangat besar: rentang terlebar dimiliki laju aliran kipas sekunder FT_8302 (19.160,62), sedangkan rentang tersempit dimiliki pot pressure PTCA_8322A (0,67), sehingga rasionya mencapai sekitar 28.600 kali. Rata-ratanya juga berkisar dari −370,63 (SXLTCYY) hingga 46.462,88 (FT_8301). Sebagian besar sensor relatif simetris (|*skewness*| < 0,8). Pengecualiannya adalah arus motor ID fan YFJ3_AI (*skewness* 1,94; kurtosis 38,46) dan getaran YFJ3_ZD2 (*skewness* 1,22) yang memiliki ekor kanan panjang. Pada acuan TE_8332A, 8,14% sampel berada di luar rentang 530–545 °C. Angka ini sedikit berbeda dari 8,6% yang dilaporkan penyusun dataset [1], kemungkinan karena perbedaan versi berkas.

TABLE II. STATISTIK DESKRIPTIF 30 ATRIBUT DATA MENTAH

Sensor	Mean	Std	Min	Maks	Skew
PT_8313A	−137,71	55,38	−484,70	75,33	−0,61
PT_8313B	−188,61	53,90	−549,57	51,83	−0,62
PT_8313C	−153,34	51,31	−509,12	126,28	−0,66
PT_8313D	−118,44	52,45	−501,23	256,53	−0,70
PT_8313E	−167,36	56,80	−586,83	245,11	−0,69
PT_8313F	−156,95	55,65	−562,75	174,87	−0,68
PTCA_8322A	9,77	0,08	9,42	10,09	−0,56
PTCA_8324	9,44	0,07	9,06	9,77	−0,76
TE_8319A	356,88	5,99	342,53	376,50	−0,04
TE_8319B	390,97	9,15	367,29	420,58	−0,08
TE_8313B	774,06	10,68	737,70	818,08	−0,23
TE_8303	210,84	4,95	198,64	226,38	0,07
TE_8304	222,22	3,20	214,05	233,16	0,04
TV_8329ZC	16,08	4,86	1,64	35,48	0,12
FT_8301	46.462,88	1.698,99	40.773,29	53.047,27	0,06
FT_8302	19.603,77	2.095,22	11.446,04	30.606,66	0,15
FT_8306A	700,78	23,65	262,49	754,38	−0,31
AIR_8301A	2,09	0,34	0,78	4,56	0,57
FT_8306B	619,41	19,62	304,96	671,47	0,13
AIR_8301B	2,23	0,39	0,80	5,05	0,69
YFJ3_AI	22,76	0,98	16,74	51,28	1,94
YFJ3_ZD1	5,77	0,57	2,13	9,11	0,17
YFJ3_ZD2	6,68	1,91	2,35	24,96	1,22
SXLTCYZ	−125,19	56,13	−468,54	86,20	−0,58
SXLTCYY	−370,63	61,73	−707,31	−19,13	−0,17
ZCLCCY	10.412,32	507,34	8.897,17	11.819,51	−0,19
YCLCCY	10.356,22	498,08	8.894,89	11.797,82	−0,20
YJJWSLL	2,78	0,33	1,60	4,30	0,17
ZZQBCHLL	59,76	2,38	50,66	70,87	−0,29
TE_8332A (acuan)	537,52	4,33	517,05	550,49	−0,25

Sebaran tiap sensor setelah skala robust ditunjukkan pada Fig. 3. Dengan pagar 1,5×IQR, porsi outlier per sensor berkisar 0–3,88%, tertinggi pada PTCA_8324 (3,88%), AIR_8301A (3,44%), dan AIR_8301B (3,39%). Dengan pagar 3×IQR, outlier ekstrem terbanyak terdapat pada YFJ3_AI (557 sampel atau 0,64%) yang mencapai sekitar 27 IQR di atas median. Sebaliknya, sensor suhu, FT_8301, ZCLCCY, dan YCLCCY tidak memiliki outlier ekstrem sama sekali.

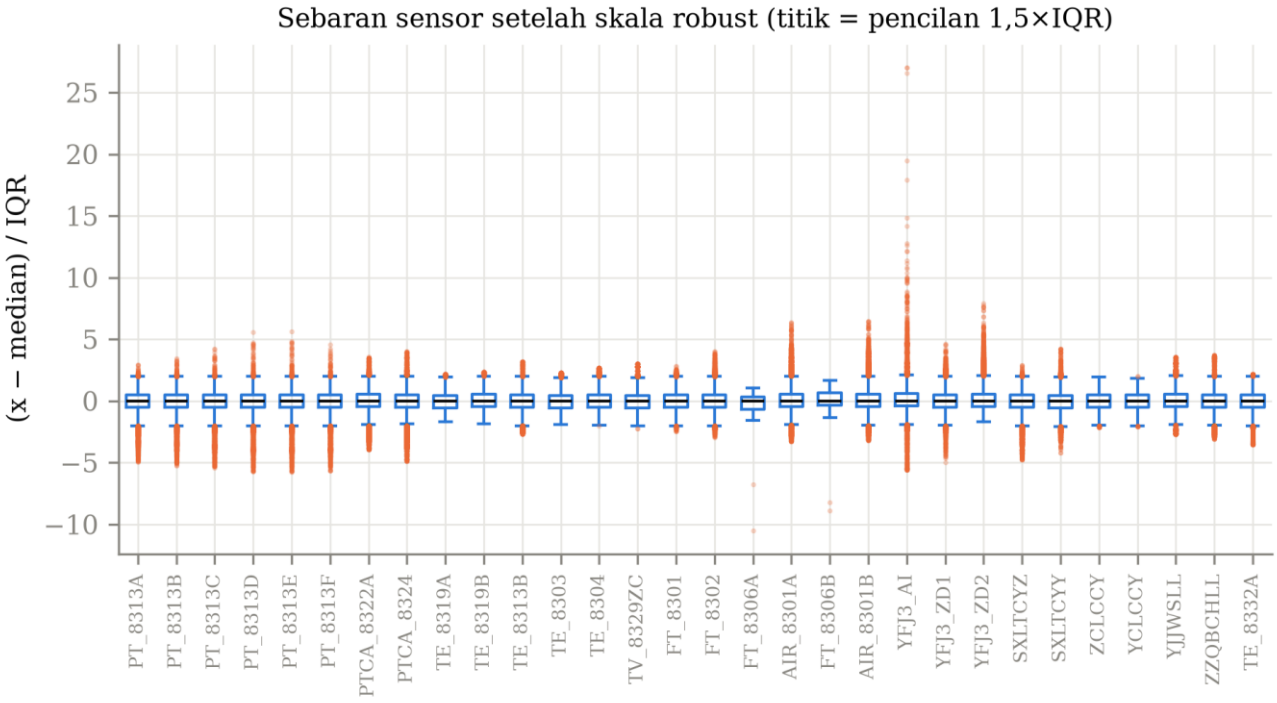


Fig. 4. Boxplot 30 atribut pada skala robust (x − median)/IQR; titik menandai outlier di luar pagar 1,5×IQR.

Matriks korelasi pada Fig. 4 memperlihatkan redundansi yang kuat antar-sensor. Tekanan tungku atas saling berkorelasi sangat tinggi, misalnya PT_8313E dan PT_8313F ($r = 0{,}992$) serta PT_8313D dan PT_8313E (0,991). Pasangan kiri–kanan juga berkorelasi tinggi, yaitu ZCLCCY dan YCLCCY (0,977) serta PTCA_8322A dan PTCA_8324 (0,947). Bukaan katup TV_8329ZC berkorelasi 0,946 dengan laju air *desuperheater* YJJWSLL, yang konsisten secara fisik karena katup tersebut mengatur aliran air. Redundansi ini menjadi alasan penggunaan PCA sebelum K-Means.

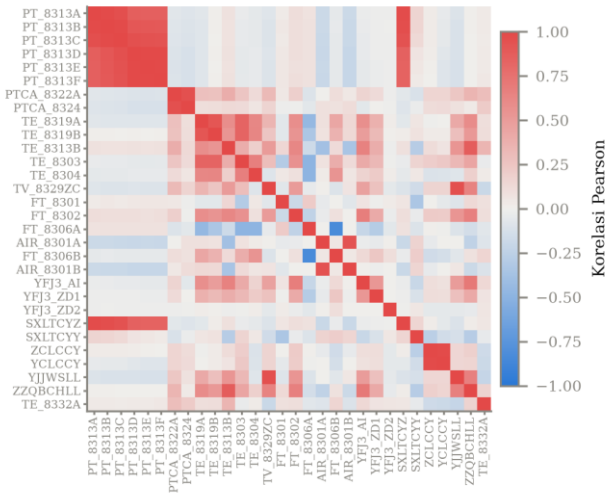


Fig. 5. Matriks korelasi Pearson 30 atribut (skala divergen biru–abu–merah, −1 hingga 1).

Temporal dependency terbukti kuat: median autokorelasi adalah 0,988 pada lag 5 detik; 0,914 pada 1 menit; 0,654 pada 5 menit; 0,429 pada 30 menit; dan 0,317 pada 1 jam. TE_8319A masih memiliki autokorelasi 0,816 pada 1 jam, sedangkan PT_8313A turun menjadi 0,477 pada 5 menit dan YFJ3_ZD2 hanya 0,126 pada 5 detik. FT_8306A/B menunjukkan pergeseran level sekitar 30 Maret, sementara ZCLCCY/YCLCCY berpola gigi gergaji periodik. Observasi berurutan tidak independen.

B. Hasil Praproses dan Reduksi Dimensi

Sebanyak 30 nilai hilang pada YJJWSLL, yang terbagi menjadi dua celah sepanjang 28 sampel (28 Maret, 06.22–06.24) dan 2 sampel (30 Maret, 05.54), berhasil diinterpolasi. *Winsorizing* 3×IQR mengubah 3.843 dari 2.505.600 sel (0,153%) pada 20 sensor, terbanyak pada YFJ3_AI (557) dan PTCA_8324 (417), tanpa menyentuh satu pun sensor suhu. Setelah *robust scaling*, simpangan baku antar-sensor yang semula berkisar 0,072 hingga 2.094,56 menjadi 0,556 hingga 0,902. Ketimpangan skala dengan demikian tereliminasi. Representasi jendela menghasilkan 1.440 jendela × 87 fitur. Kriteria Kaiser mempertahankan 26 komponen utama yang menjelaskan 86,1% varians. Sebagai pembanding, *baseline* A dan B masing-masing mempertahankan 8 komponen (84,9% dan 88,9% varians).

C. Pemilihan Jumlah Klaster

Tabel III dan Fig. 5 menunjukkan hasil evaluasi representasi usulan untuk $k = 2$ hingga 10. Kurva WCSS turun landai dari 98.767 menjadi 73.462 tanpa siku yang tajam. Titik siku otomatis jatuh pada $k = 5$, DBI terendah pada $k = 7$ (2,319), dan Silhouette tertinggi pada $k = 2$ (0,260). Untuk $k \geq 3$, Silhouette turun ke 0,075 atau lebih rendah, yang berarti pemecahan lebih lanjut menghasilkan klaster yang saling tumpang-tindih. Sesuai aturan pada Bagian II, $k = 2$ ditetapkan sebagai jumlah klaster final. Ketidaksepakatan ketiga kriteria ini juga memperlihatkan bahwa memilih k hanya dari Elbow, seperti pada [3], dapat menyesatkan bila struktur klasternya lemah.

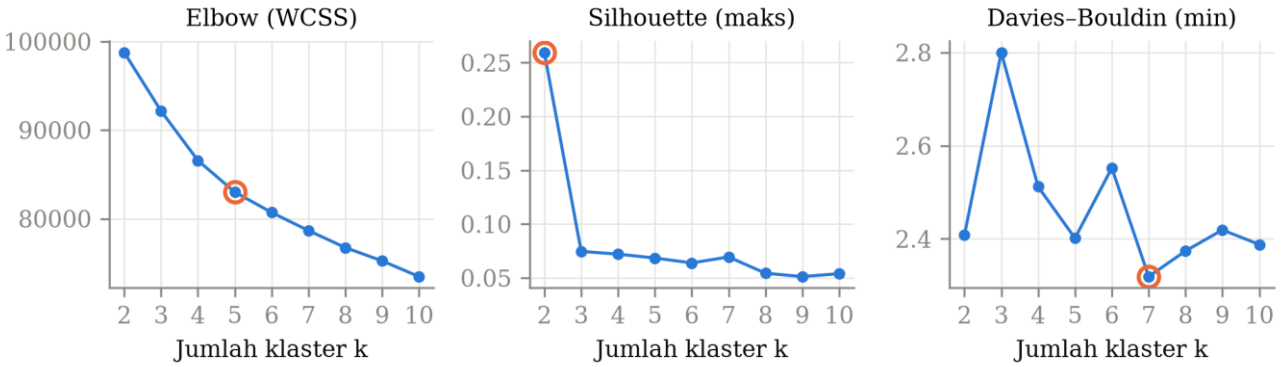


Fig. 6. Pemilihan k pada representasi usulan: kurva Elbow (WCSS), Silhouette, dan Davies–Bouldin untuk k = 2 hingga 10; lingkaran menandai titik terpilih tiap kriteria.

TABLE III. EVALUASI JUMLAH KLASTER PADA REPRESENTASI USULAN

k	WCSS	Silhouette	DBI
2	98.767,47	0,2595	2,4080
3	92.151,78	0,0746	2,8001
4	86.570,25	0,0721	2,5120
5	83.003,01	0,0685	2,4015
6	80.702,52	0,0639	2,5522
7	78.655,34	0,0695	2,3191
8	76.735,97	0,0543	2,3741
9	75.233,51	0,0512	2,4192
10	73.462,19	0,0539	2,3881

D. Perbandingan Representasi dan Sensitivitas Jendela

Tabel IV membandingkan ketiga representasi pada *k* terbaik masing-masing, dan ketiganya sama-sama memilih *k* = 2. Representasi usulan menghasilkan Silhouette 0,260, naik 56,7% dibanding *baseline* A (0,166) dan 49,3% dibanding *baseline* B (0,174). Sebaliknya, DBI representasi usulan lebih buruk (2,408 berbanding 2,019 dan 1,955), dan pola ini konsisten pada semua *k*. Hal ini terjadi karena klaster yang terbentuk berukuran timpang dan klaster kecilnya tersebar luas, sehingga suku sebaran S_i pada DBI membesar. Perbandingan DBI juga tidak sepenuhnya setara karena representasi usulan berada pada ruang 26 dimensi, sedangkan kedua *baseline* hanya 8 dimensi.

TABLE IV. PERBANDINGAN REPRESENTASI PADA K TERBAIK

Representasi	n	PC	k	Silhouette	DBI
A. Titik per titik	86.400	8	2	0,1656	2,0193
B. Rata-rata jendela	1.440	8	2	0,1738	1,9553
C. Usulan (mean, std, slope)	**1.440**	**26**	**2**	**0,2595**	**2,4080**

Tabel V menunjukkan bahwa jendela 5 menit memberikan Silhouette tertinggi pada k = 2 (0,260), dibandingkan 1 menit (0,078), 10 menit (0,200), dan 30 menit (0,113). Jendela pendek kurang merangkum dinamika, sedangkan jendela panjang dapat meredam fluktuasi singkat. Pada k = 3, jendela 10 menit memberikan Silhouette tertinggi di antara durasi yang diuji (0,156).

TABLE V. SENSITIVITAS PANJANG JENDELA W (SILHOUETTE / DBI)

W (sampel)	Jendela	k = 2	k = 3	k = 4
1 mnt (12)	7.200	0,0783 / 3,2545	0,0793 / 2,6610	0,0689 / 2,5477
5 mnt (60)	1.440	0,2595 / 2,4080	0,0746 / 2,8001	0,0721 / 2,5120
10 mnt (120)	720	0,2002 / 2,6643	0,1560 / 2,4502	0,0713 / 2,4955
30 mnt (360)	240	0,1131 / 2,9849	0,0911 / 2,6215	0,0902 / 2,4164

E. Interpretasi Klaster

Profil klaster pada Fig. 6 dan Tabel VI menunjukkan bahwa kedua klaster dibedakan oleh dinamika, bukan oleh level operasi. Klaster 0 (1.258 jendela, 87,4% waktu) adalah kondisi stabil. Klaster 1 (182 jendela, 12,6% waktu) dicirikan oleh simpangan baku tekanan tungku PT_8313A–F dan beda tekanan SXLTCYZ yang tinggi (+1,44 hingga +1,60 dalam satuan z), disertai slope negatif (−1,19 hingga −1,25 z). Artinya, dalam jendela tersebut tekanan tungku berfluktuasi kuat dan bergerak makin negatif, yang mengindikasikan ketidakstabilan pembakaran atau tarikan udara. Sebaliknya, level operasinya hampir sama, misalnya laju uap utama ZZQBCHLL 60,14 berbanding 59,71 dan aliran kipas primer FT_8301 46.791 berbanding 46.415. K-Means titik per titik tidak dapat menangkap perbedaan ini karena satu sampel 5 detik tidak membawa informasi volatilitas.

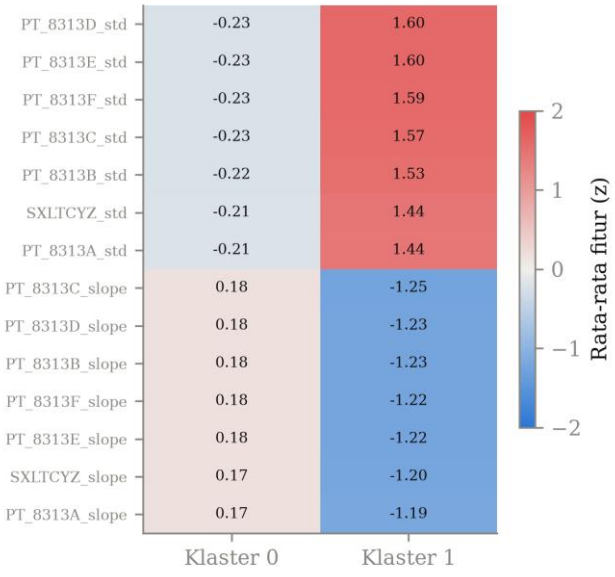


Fig. 7. Profil klaster (k = 2): rata-rata 14 fitur jendela paling pembeda dalam satuan z; merah lebih tinggi dan biru lebih rendah daripada rata-rata seluruh jendela.

TABLE VI. RINGKASAN KLASTER DAN ACUAN EKSTERNAL TE_8332A

Klaster	Jendela	Waktu (%)	TE_8332A (°C)	Abnormal (%)	Std PT (z)
0 (stabil)	1.258	87,4	537,42	7,55	−0,23
1 (fluktuatif)	182	12,6	538,21	12,28	+1,55

Fig. 7 menunjukkan linimasa dan proyeksi klaster pada PC1–PC2. Dalam proyeksi ini, klaster 0 lebih kompak, sedangkan klaster 1 lebih menyebar dan bertumpang-tindih. Klaster 1 muncul dalam 144 episode singkat, dengan durasi rata-rata sekitar 6 menit dan maksimum 20 menit, serta porsi

waktu 10,4–14,6% per hari. Porsi suhu uap di luar 530–545 °C mencapai 12,28%, dibandingkan 7,55% pada klaster 0. Keterkaitan ini bersifat deskriptif dan belum membuktikan sebab-akibat karena jendela berurutan saling berkorelasi.

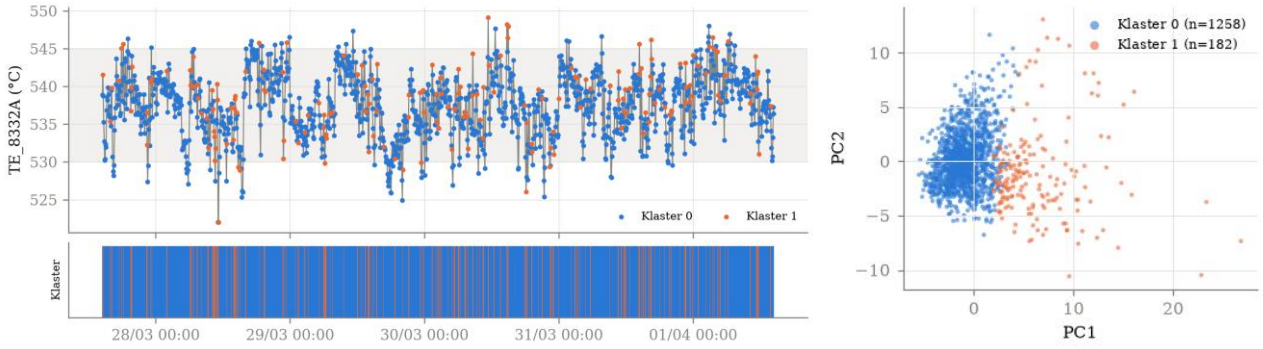


Fig. 8. Hasil klasterisasi: (kiri) linimasa rata-rata TE_8332A per jendela 5 menit dan label klaster, dengan pita normal 530–545 °C; (kanan) proyeksi klaster pada PC1–PC2. Klasterisasi menggunakan 26 komponen PCA.

F. *Pembahasan dan Keterbatasan*

Secara keseluruhan, struktur klaster pada data ini tergolong lemah. Silhouette tertinggi hanya 0,260, dan seluruh representasi berada di bawah 0,18 untuk $k \geq 3$. Hal ini wajar karena boiler beroperasi kontinu dalam satu rezim beban selama lima hari tanpa *start-up* maupun *shutdown*, sehingga variasinya berupa drift bertahap, bukan kelompok yang terpisah tegas. Dalam kondisi ini, kontribusi representasi jendela temporal adalah menemukan dimensi yang tidak terlihat oleh pendekatan titik per titik, yaitu stabilitas dinamis tekanan tungku. Hasil ini sejalan dengan temuan bahwa fitur volatilitas berperan penting dalam klasterisasi deret waktu industri [10], [11].

Penelitian ini memiliki beberapa keterbatasan. (1) Silhouette dan DBI tidak sepakat, sehingga keunggulan representasi usulan hanya berlaku pada Silhouette. (2) Data hanya mencakup lima hari dari satu boiler. (3) Panjang jendela tetap 5 menit, dan K-Means mengasumsikan klaster berbentuk sferis. (4) Interpolasi linear belum dibandingkan dengan AutoReg [1]. Seluruh kode tersedia pada repositori di Lampiran agar hasilnya dapat direproduksi.

IV. KESIMPULAN DAN SARAN

A. *Kesimpulan*

EDA mengonfirmasi scale disparity, temporal dependency, nilai hilang, outlier, dan redundansi sensor. Interpolasi linear, winsorizing 3×IQR, dan robust scaling menyiapkan 29 sensor untuk klasterisasi; winsorizing mengubah 0,153% sel, dan simpangan baku antar-sensor setelah scaling berkisar 0,556–0,902.

Non-overlapping windows 5 menit dengan mean, simpangan baku, slope, dan PCA menghasilkan Silhouette 0,260 pada k = 2, lebih tinggi daripada kedua baseline. Namun, DBI lebih buruk, sehingga keunggulan bergantung pada metrik. Elbow, Silhouette, dan DBI memilih k berbeda (5, 2, 7), menegaskan perlunya evaluasi dengan beberapa kriteria.

Klaster fluktuatif mencakup 12,6% waktu dan dicirikan oleh dinamika tekanan, dengan porsi suhu uap abnormal 12,28% dibandingkan 7,55% pada klaster stabil. Representasi temporal membantu menafsirkan stabilitas dinamis, tetapi struktur klaster lemah dan keterkaitan dengan suhu uap bersifat deskriptif.

B. *Saran*

- Mengembangkan representasi multi-skala [9], seleksi atau pembobotan sensor redundan [12], serta algoritma seperti HDBSCAN [9] atau Gaussian Mixture Model dan jarak khusus time series untuk klaster yang timpang.
- Membandingkan interpolasi dengan AutoReg [1], menguji data yang lebih panjang dan boiler lain, serta mengevaluasi kestabilan melalui variasi inisialisasi dan block bootstrap yang memperhitungkan autokorelasi.
- Mengevaluasi potensi klaster fluktuatif sebagai indikator operasional melalui validasi dengan catatan gangguan dan penilaian operator.

DAFTAR PUSTAKA

[1] W. Hu, A. Jiang, K. Chen, J. Zheng, W. Shang, and Z. Cao, "A long-tailed distribution timeseries dataset in boiler equipment," *Sci. Data*, vol. 12, Art. no. 742, 2025, doi: 10.1038/s41597-025-05096-4.

[2] "A long-tailed distribution time-series dataset in boiler equipment," figshare, 2025. [Online]. Available: https://figshare.com/articles/dataset/A_long-tailed_distribution_time-series_dataset_in_boiler_equipment/28822793

[3] Y. Choi *et al.*, "Time-series clustering approach for training data selection of a data-driven predictive model: Application to an industrial bio 2,3-butanediol distillation process," *Comput. Chem. Eng.*, vol. 161, Art. no. 107758, 2022, doi: 10.1016/j.compchemeng.2022.107758.

[4] J. Köhne, L. Henning, and C. Gühmann, "Autoencoder-based iterative modeling and multivariate time-series subsequence clustering algorithm," *IEEE Access*, vol. 11, pp. 18868–18886, 2023, doi: 10.1109/ACCESS.2023.3247564.

[5] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *J. Comput. Appl. Math.*, vol. 20, pp. 53–65, 1987.

[6] D. L. Davies and D. W. Bouldin, "A cluster separation measure," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. PAMI-1, no. 2, pp. 224–227, 1979.

[7] M. J. Page *et al.*, "The PRISMA 2020 statement: An updated guideline for reporting systematic reviews," *BMJ*, vol. 372, Art. no. n71, 2021, doi: 10.1136/bmj.n71.

[8] J. Enes, R. R. Expósito, J. Fuentes, J. López Cacheiro, and J. Touriño, "A pipeline architecture for feature-based unsupervised clustering using multivariate time series from HPC jobs," *Inf. Fusion*, vol. 93, pp. 1–20, 2023, doi: 10.1016/j.inffus.2022.12.017.

[9] Y. Shi, J. Guo, J. Tian, T. Yi, Y. Meng, and Z. Tian, "Multi-view clustering-based outlier detection for converter transformer multivariate time-series data," *Sensors*, vol. 25, no. 17, Art. no. 5216, 2025, doi: 10.3390/s25175216.

[10] D. Leiria *et al.*, “Is it returning too hot? Time series segmentation and feature clustering of end-user substation faults in district heating systems,” *Appl. Energy*, vol. 381, Art. no. 125122, 2025, doi: 10.1016/j.apenergy.2024.125122.

[11] R. Martins, H. Morais, and L. Pereira, “Unveiling energy usage patterns in industrial kitchens: From detection to clustering of appliance usage,” *Comput. Electr. Eng.*, vol. 123, Art. no. 110163, 2025, doi: 10.1016/j.compeleceng.2025.110163.

[12] K. Li, Z. Tang, S. Liang, Z. Li, and B. Liang, “MLAD: A multi-task learning framework for anomaly detection,” *Sensors*, vol. 25, no. 13, Art. no. 4115, 2025, doi: 10.3390/s25134115.

[13] M. Liu, X. Wang, W. Qiao, H. Shang, Z. Yan, and Z. Qin, “A sensor data prediction and early-warning method for coal mining faces based on the MTGNN-Bayesian-IF-DBSCAN algorithm,” *Sensors*, vol. 25, no. 15, Art. no. 4717, 2025, doi: 10.3390/s25154717.

[14] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA, USA: Addison-Wesley, 1977.

[15] H. F. Kaiser, “The application of electronic computers to factor analysis,” *Educ. Psychol. Meas.*, vol. 20, no. 1, pp. 141–151, 1960.

[16] J. MacQueen, “Some methods for classification and analysis of multivariate observations,” in *Proc. 5th Berkeley Symp. Math. Statist. Probab.*, vol. 1, 1967, pp. 281–297.